НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Факультет Компьютерных Наук

Департамент Программной Инженерии

Контрольное Домашнее Задание

по дисциплине «Алгоритмы и Структуры Данных»

ОТЧЕТ

Выполнил:
Студент 2 курса группы БПИ151
Куприянов Кирилл Игорвеич

Москва 2016

Содержание

1 Постановка задачи

Необходимо было реализовать с использованием языка $C++$ программы для архивирования и текстовых файлов. При этом использовать два известных алгоритма кодирования информации:

1. Хаффмана (не адаптивный, простой)
2. Шеннона-Фано

Обе реализации поместить в одном файле main.cpp, содержащем соответствующие методы:

1. метод архивирования, использующий алгоритм Хаффмана, вход: текстовый файл <name>.txt (кодировка UTF-8) выход: архивированный файл <name>.haff
2. метод разархивирования, использующий алгоритм Хаффмана, вход: архивированный файл <name>.haff выход: разархивированный файл <name>-unz-h.txt (кодировка UTF-8)
3. метод архивирования, использующий алгоритм Шеннона-Фано, вход: текстовый файл <name>.txt (кодировка UTF-8) выход: архивированный файл <name>.shan
4. метод разархивирования, использующий алгоритм Шеннона-Фано. вход: архивированный файл <name>.shan выход: разархивированный файл <name>-unz-s.txt (кодировка UTF-8)

Выбор алгоритма осуществляется с помощью флага командной строки.

Оба алгоритма работают в два прохода. Сначала строится таблица частот встречаемости символов в конкретном архивируемом файле (кодируем только те символы из набора допустимых, которые реально встречаются в файле). Затем строится кодовое дерево (не обязательное). По нему (или по таблице кодов) и архивируется файл. Для разархивирования алгоритмам потребуется знать таблицу, которая использовалась при архивировании. Соответствующая таблица должна сохраняться в архивном файле в самом его начале и использоваться при разархивировании. В начале пишется количество различных символов n, имеющихся в кодируемом файле, а затем n пар (код символа UTF-8, битовый код в архиве). Порядок — по убыванию частоты встречаемости символа в кодируемом файле.

Провести вычислительный эксперимент с целью оценки реализованных алгоритмов архивации / разархивации. Оценить количество элементарных операций каждого алгоритма. Для этого

1. Подготовить тестовый набор из нескольких текстовых файлов разного объема (20, 40, 60, 80, 100 Кб; 1, 2, 3 Мб — всего 8 файлов) на разных языках (ru, en - кодировка UTF-8) с разным набором символов в каждом файле, а именно:
   (a) первый набор: символы латинского алфавита и пробел
   (b) второй набор: символы из первого набора + символы русского алфавита
   (c) третий набор: символы из второго набора + следующие знаки и спецсимволы: знаки арифметики „+ - * / =“, знаки препинания „. , ; : ? !“, „% @ # $ & ‘’, скобки разных типов „( ) [ ] < >“ , кавычки „„“”),
2. Измерить (экспериментально) количество операций (в рамках модели RAM (взять из лекционного материала)), выполняемых за время работы (архивирования, разархивирования) каждого алгоритма на нескольких различных (не менее трех) файлах для каждого размера входного файла и набора символов (итого получается $8 \times 3 \times 3 = 72$ эксперимента по архивированию и 72 по разархивированию для каждого алгоритма,

т.е. Всего минимум $144 \times 2 = 288$). Для повышения достоверности результатов каждый эксперимент можно повторить несколько (5-10) раз на файлах (с одним возможным набором символов) одного размера с последующим усреднением результата.

Подготовить отчет по итогам работы, содержащий постановку задачи, описание алгоритмов и задействованных структур данных, описание реализации, обобщенные результаты измерения эффективности алгоритмов, описание использованных инструментов (например, если использовались скрипты автоматизации), выводы о соответствии результатов экспериментальной проверки с теоретическими оценками эффективности исследуемых алгоритмов. Отчет также должен содержать измерения качества архивации (степень сжатия = отношение размеров выходного и входного файлов), оценку связи между степенью сжатия для различных входных файлов (как влияют объем, язык, набор символов, их разнообразие?) и временем работы (количеством операций) для каждого алгоритма.

Было выполнено: Всё. + построены дополнительные графики

2 Описание алгоритмов и использованных СД

2.1 Для решения задачи алгоритмом Хаффмана

2.1.1 Структуры данных

Для реализации архивирования - деархивирования алгоритмом Хаффмана я использовал следующие **структуры данных**:

- **Бинарное дерево** с узлами - указателями на объекты класса Node. Для их хранения использовался двусвязный список.
- **map <char, int>** - для хранения таблицы частот
- **map <char, vector<bool> >** - для хранения таблицы вида «символ - его код»

2.1.2 Алгоритмы и функции

Описание использованных **алгоритмов**

Использовались следующие функции:

- **vector<char> getSymbols(string)** - для заполнения вектора символов символами из файла. По указанному пути файла создает поток и считывает все символы в вектор. Затем удаляет (делает push_back) последний элемент - константу EOF, поскольку она лишняя. Сложность - $O(n)$
- **map<char, int> getFreq(vector<char>)** - для составления таблицы частот. По данному вектору символов составляет map<char, int> - где каждому символу ставится в соответствие его частота появления в данном вектре
- **void buildTree(map<char, int>)** - для построения дерева. Создает list<Node *> для содержания узлов деревьев. Изначально каждый Node в списке имеет значение c = char из входной map, n = частоте появления (значение int во входной map). Указатели на левых и правых детей равны $nullptr$. Процедура построения дерева происходит следующем образом: Список сортируется по возрастанию частоты появления символов (для этого использую функцию sort и структуру Compare, где перегружаю оператор ()). Затем берутся первые 2 элемента списка, они становятся детьми нового узла, который кладется в начало списка, а 2 прошлых - удаляются. Эта процедура происходит рекурсивно до тех пор, пока не останется в списке только 1 элемент - корень. Сложность - $O(n)$
- **void buildTable(Node*)** - для построения таблицы кодов, используя дерево. Начиная с корня, идем по дереву налево. Если левый ребенок не равен nullptr, добавляем во временный вектор code 0 и вызываем эту функцию, передавая в качетве аргумента указатель на этого ребенка. Аналогично с правым ребенком, только добавляем в вектор code не 0, а 1. Если же и левуй и правый дети - nullptr, то мы считаем, что вектор code представляет собой код символа, который находится в текущем узле и записываем это соответствие в map <char, vector <bool> >
- **void encodeHuff(string , string)** - для «архивации» файла. Архивация происходит следующим образом. Открываю потоки ввода и вывода. Для потока вывода ставлю флаги - std::ios::binary, и std::ios::out, поскольку я буду писать в бинарный файл. Считываю все символы из входного файла в vector<char>, с помощью указанной выше функции. Записваю в выходной файл первым делом длину того вектра - количество символов в исходном файле. Это понадобится дальше при разархивировании. Затем составляю

таблицу частот и вторым байтом записываю длину таблицы, другими словами, кол-во уникальных символов. Если эта длина равна еденице, значит, что исходный файл заполнен одним конкретным символом "первый байт"количество раз. В таком случае, мы его считываем и пишем его столько раз в выходной файл. При разархивировании это учитываем. Если же количество уникальных символов не равно 1, то продолжаем. Записываем таблицу соответствий сида «символ - его частота». Затем строим дерево, таблицу кодов, проходимся по исходному файлу и выводим в архив код каждого символа следующим образом:

Поскольку писать побитово нельзя, пишем побайтово. Аккумулируем биты в переменной buf и считаем сколько бит мы уже записали. Как только это количество станет равно 8, пишум buf в файл и обнуляем его. В конце, если у нас кол-во бито оказалось не кратным 8, пишум то, что осталось для того, чтобы заполнить недостающие биты. НЕ считать лишнего при разархивировании нам поможет первый байт - кол-во символов в исходном сообщении.

- **void decodeHuff(string , string)** - для «деархивации» файла. Открываю потоки, считываю первый байт - кол-во символов. Если оно равно 1, то считываю второй байт - сколько раз повторяется этот конкретный символ. Затем считываю этот символ и пишу в аутпут его такое количество раз. Если же первый байт не еденица, то идем дальше. Считываем длину таблицы частот и такое количество раз считываем следующие байты, попутно инициализируя таблицу частот. На основе этой таблицы строится дерево. Затем декодирую само сообщение. Считываю байт информации в char byte и смотрю на него побитово, если бит равен 1, то иду по дереву направо, если 0, то налево. Когда дошел до листа, я дописываю в результирующую строку символ в листе. Когда просмотрел 8 битов, считывю новый. Затем, после того, как прочитал весь файл, записываю в аутпут результирующую строку, но не всю, а только такое количество символов, сколько я считал в начале.

2.2 Для решения задачи алгоритмом Шеннона-Фано

2.2.1 Структуры данных

Для реализации архивирования - деархивирования алгоритмом Шеннона-Фано я использовал следующие **структуры данных**:

- **struct node** - основная структура для работы с алгоритмом Шеннона-Фано с двумя полями - char ch (символ) и float p (его вероятность появления в тексте)
- **node *freqTable** - таблица вероятностей, представляет собой динамический массив из элементов node
- **map<char, vector<bool> > table** - аналогичная (таблице кодов Хаффмана) таблица, которой каждому символу поставлен в соответствие его код

2.2.2 Алгоритмы и функции

Описание использованных **алгоритмов**

Использовались следующие функции:

- **void shannonFano(int, int)** - функция, которая, собственно, выполняет процедуру Шеннона-Фано. Строит таблицу «символ-код». Это рекрсивная функция. База: return, если в группе всего лишь 1 символ. Если 2 символа, первому добавляем к коду 0, а ко второму - 1. Для остальныйх вариантов: проходим по (отсортиированнной!) таблице, постепенно инкрементируя текущую сумму вероятностей до момента пока она не станет

больше либо равной половине полной вероятности, а пока она меньше половины, мы на каждом шаге приписываем к коду текущего символа 0. Как только этот момент настал, добавляем к кодам тех элементов, что ниже 1. Рекурсивно вызываем функцию для первой и второй групп. Получили построенную таблицу кодов по алгориитму Шеннона-Фано.

- **void encodeSF(string, string)** - функция, идентичная аналогичной для кода Хаффмана. Длина сообщения записывается первым битом, кол-во уникальных символов - вторым, затем таблица соответствий символ - вероятность, затем само сообщение, так же, как и для алгоритма Хаффмана. Со случаем, когда длина таблицы = 1 разбираемся так же, как и там. Различие - в моей реализации задачи алгоритмом Шеннона-Фано *не используется* дерево, используется лишь таблица кодов.

- **void decodeSF(string, string)** - функция, идентичная аналогичной для кода Хаффмана. После получения таблицы вероятностей, вызываю функцию shannonFano для построения таблицы кодов. По ней и декодируется сообщени, лежащее в последних байтах архива. Как только получаем новый битик, добавляем его во временный vector<bool> и по мере добавления, проверяю, есть ли он в таблице кодов с помощью функции isInTable. Если он там есть, ищу символ, соответствующий этому коду при помощи функции getchar.

- **char getchar(vector<bool>)** - вспомогательная функция. Возвращает символ, которому в таблице кодов соответствует данный вектор или 0, если такого нет.

3 Описание плана эксперимента

План эксперимента состоит в следующем:

- Сгенерировать набор тестоых файлов
- Запустить программу на них, подсчитав количество операций, и получив таблицу
- По полученной таблице построить графики
- Проанализировать результаты эксперимента

Для начала нужно сгенерировать тестовый набор из файлов разных размеров (20, 40, 60, 80, 100 Кб, 1, 2, 3 Мб) и разных наборов символов, каждого по три штуки, итого $8 \times 3 \times 3 = 72$ файла. Для генерации тестового набора файлов будет написан скрипт на языке Python.

Для подсчета количества операций при архивировании - деархивировании двумя алгоритмами этих 72х файлов, я будет сделано следующее. Будет глобальная переменная, изначально равная 0 **long numberOfOperations** и она будет инкрементироваться там, где необходимо подсчитать действие за операцию. Вызов библиотечных функций будет считаться за одну операцию. В конце выполнения программы это число выведится в отдельный файл.

Затем для подсчета операций при всех упомянутых выше действий, будет написан еще один скрипт на языке Python. Он попутно формировать csv таблицу, записвая в нее данные о размере файлов, количесве операций, используемом алгоритме, и т.д. (табл. 1)

name	old_size	new_size	operations	algo	set	action	num	size

Таблица 1.

Для более удобного построения графиков нужно будет отфильтровать таблицу, усреднив количества операций для трех дубликатов. Отфильтровка будет производится в тетрадке jupyter notebook на языке Python, при помощи библиотек pandas и numpy.

Построение графиков будет проводиться в той же среде, при помощи библиотеки matplotlib.

4 Результаты эксперимента - таблицы и графики

4.1 Таблицы

Ниже приведена часть отфильтрованной таблицы. Полная таблица представлена в файле filtered.csv.

name	old_size	new_size	operations	algo	set	action	num	size
set_100_1_1.haff	77611	106509	1427272	haff	1	d	1	100
set_100_2_1.haff	76829	106512	1435777	haff	2	d	1	100
set_100_3_1.haff	83701	106510	1570388	haff	3	d	1	100
set_1_1_1.haff	732537	1007739	13462131	haff	1	d	1	1
set_1_2_1.haff	724456	1007782	13341756	haff	2	d	1	1
set_1_3_1.haff	785493	1007785	14406953	haff	3	d	1	1
set_20_1_1.haff	18098	24579	333718	haff	1	d	1	20
set_20_2_1.haff	18202	24582	356596	haff	2	d	1	20
set_20_3_1.haff	19873	24579	404576	haff	3	d	1	20
set_2_1_1.haff	1458962	2007285	26810733	haff	1	d	1	2
set_2_2_1.haff	1441710	2007381	26543748	haff	2	d	1	2
set_2_3_1.haff	1564668	2007370	28647416	haff	3	d	1	2
set_3_1_1.haff	2185326	3006831	40159281	haff	1	d	1	3
set_3_2_1.haff	2159711	3006951	39751799	haff	2	d	1	3
set_3_3_1.haff	2342968	3006948	42881756	haff	3	d	1	3
set_40_1_1.haff	30004	40965	552385	haff	1	d	1	40
set_40_2_1.haff	29949	40966	572777	haff	2	d	1	40
set_40_3_1.haff	32695	40967	638421	haff	3	d	1	40
set_60_1_1.haff	47860	65544	880456	haff	1	d	1	60
set_60_2_1.haff	47573	65547	896903	haff	2	d	1	60
set_60_3_1.haff	51786	65548	988454	haff	3	d	1	60
set_80_1_1.haff	59766	81930	1099230	haff	1	d	1	80
set_80_2_1.haff	59301	81931	1113272	haff	2	d	1	80
set_80_3_1.haff	64449	81932	1221124	haff	3	d	1	80
set_100_1_1.shan	77676	106509	1636177	shan	1	d	1	100
set_100_2_1.shan	77126	106512	1623705	shan	2	d	1	100
set_100_3_1.shan	83778	106510	1733023	shan	3	d	1	100
set_1_1_1.shan	732700	1007739	15475307	shan	1	d	1	1
set_1_2_1.shan	726084	1007782	15358870	shan	2	d	1	1
set_1_3_1.shan	785787	1007785	16375760	shan	3	d	1	1
set_20_1_1.shan	18130	24579	378189	shan	1	d	1	20
set_20_2_1.shan	18275	24582	376902	shan	2	d	1	20
set_20_3_1.shan	19900	24579	402449	shan	3	d	1	20
set_2_1_1.shan	1459177	2007285	30824264	shan	1	d	1	2
set_2_2_1.shan	1444790	2007381	30581392	shan	2	d	1	2
set_2_3_1.shan	1565095	2007370	32617358	shan	3	d	1	2
set_3_1_1.shan	2185690	3006831	46173351	shan	1	d	1	3
set_3_2_1.shan	2164260	3006951	45813148	shan	2	d	1	3
set_3_3_1.shan	2343503	3006948	48852992	shan	3	d	1	3
set_40_1_1.shan	30037	40965	629726	shan	1	d	1	40
set_40_2_1.shan	30069	40966	626671	shan	2	d	1	40
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮

Описание признаков:

- **name**: имя файла, над которым будет производиться работа. Первая цифра - размер, вторая - набор символов, треться - номер дубликата, но, поскольку таблица уже отфильтрована, везде на месте третей цифры стоит 1
- **old_size**: старый размер файла, до того, как над ним было совершено действие
- **new_size**: новый размер файла, после того, как над ним было совершено действие
- **operations**: количество операций, призошедших при совершении действия
- **algo**: алгоритм, при помощи которого выполнялось действие
- **set**: номер набора символов, взят из названия
- **action**: действие, которое и совершалось над файлом (c - compress, d - decompress)
- **num**: номер дубликата, взят из названия
- **size**: размер файла, взят из названия

4.2 Графики

По приведенной таблицы были построены следующие графики (всего 8 + 12 + 2 = 22 шт.):

1. Зависимость количества операций (ось OY) от размера файла (ось OX) и размера набора символов (цвет линии) для каждого алгоритма архивирования / разархивирования. Должно быть 2 (алгоритма) * 2 (арх/разарх) * 2 (малые и большие файлы отдельно) набора графиков, на каждом 3 кривые (для каждого набора символов свой цвет)
2. Зависимость количества операций (ось OY) от размера файла (ось OX), и используемого алгоритма (цвет линии) для каждого набора символов. Должно быть 3 (набора символов) * 2 (арх/разарх) * 2 (малые и большие файлы отдельно) набора графиков, на каждом 2 кривые (для каждого алгоритма)
3. Зависимость количества операций (ось OY) от размера набора символов (ось OX) на файлах максимального размера (3 Мб) для каждого алгоритма архивирования / разархивирования (цвет линии). Должно быть 2 (арх/разарх) набора графиков, на каждом 2 кривые (для каждого алгоритма)

4.2.1 Первый набор графиков

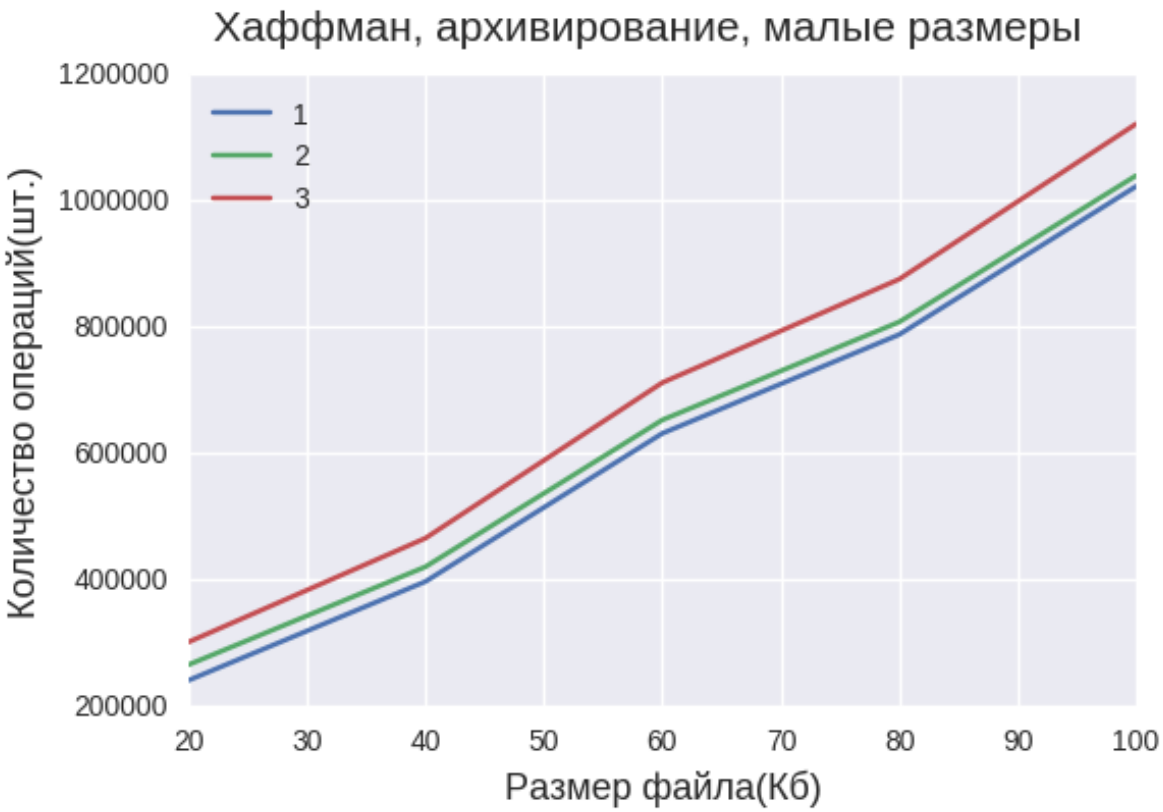

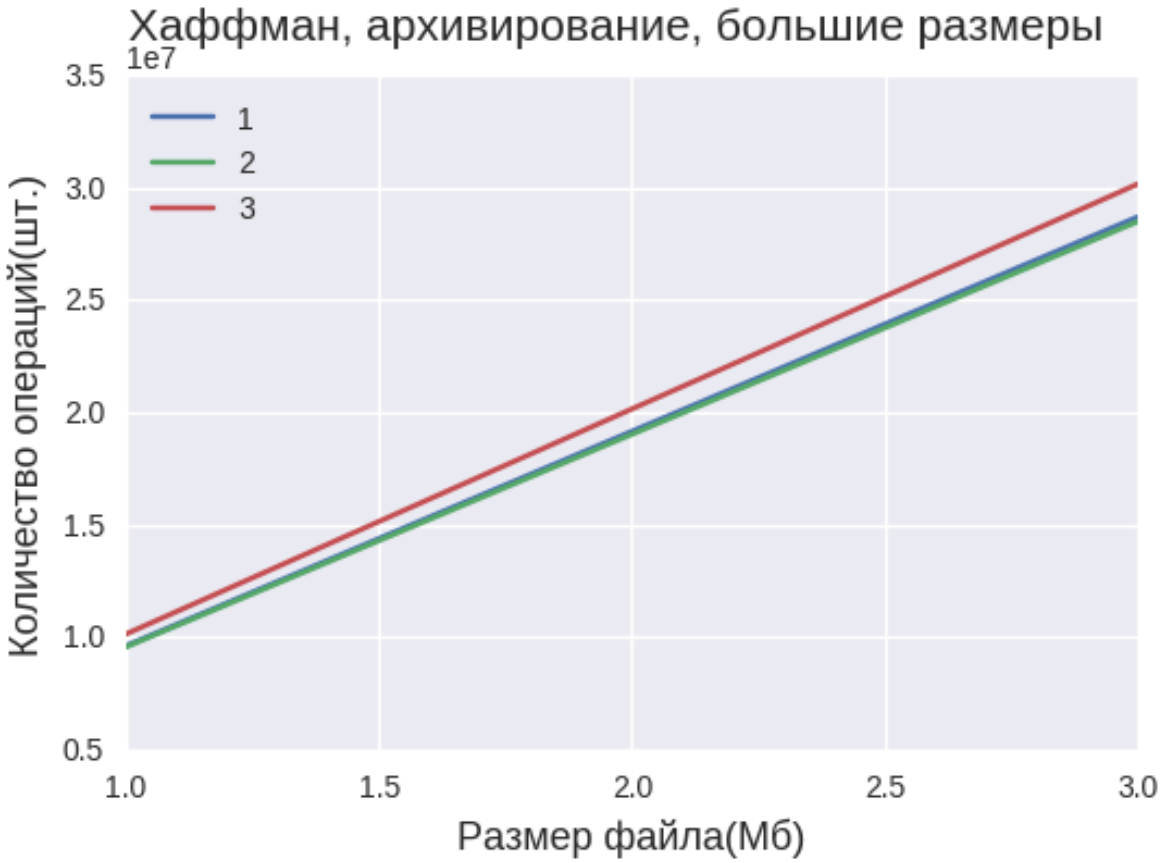

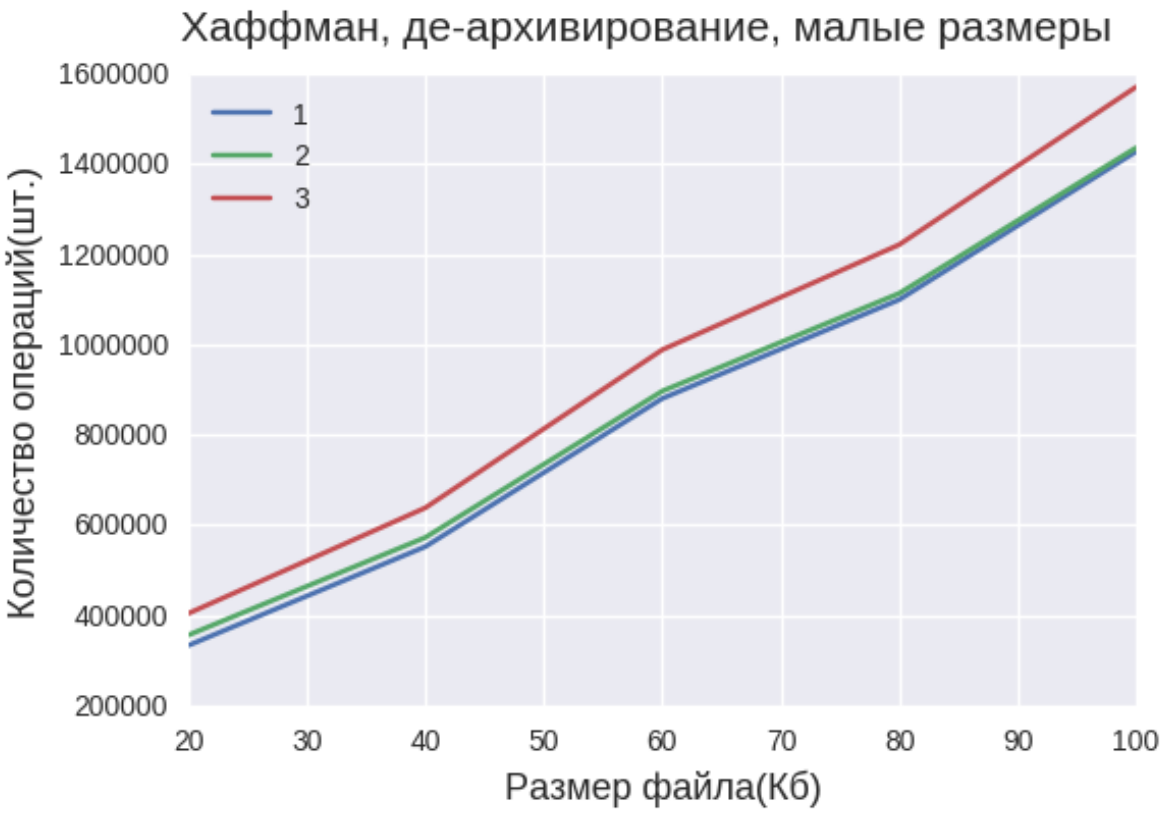
Хаффман, де-архивирование, малые размеры
1600000
1400000
1200000
1000000
800000
600000
400000
200000
Количество операций(шт.)
1
2
3
20
30
40
50
60
70
80
90
100
Размер файла(Кб)

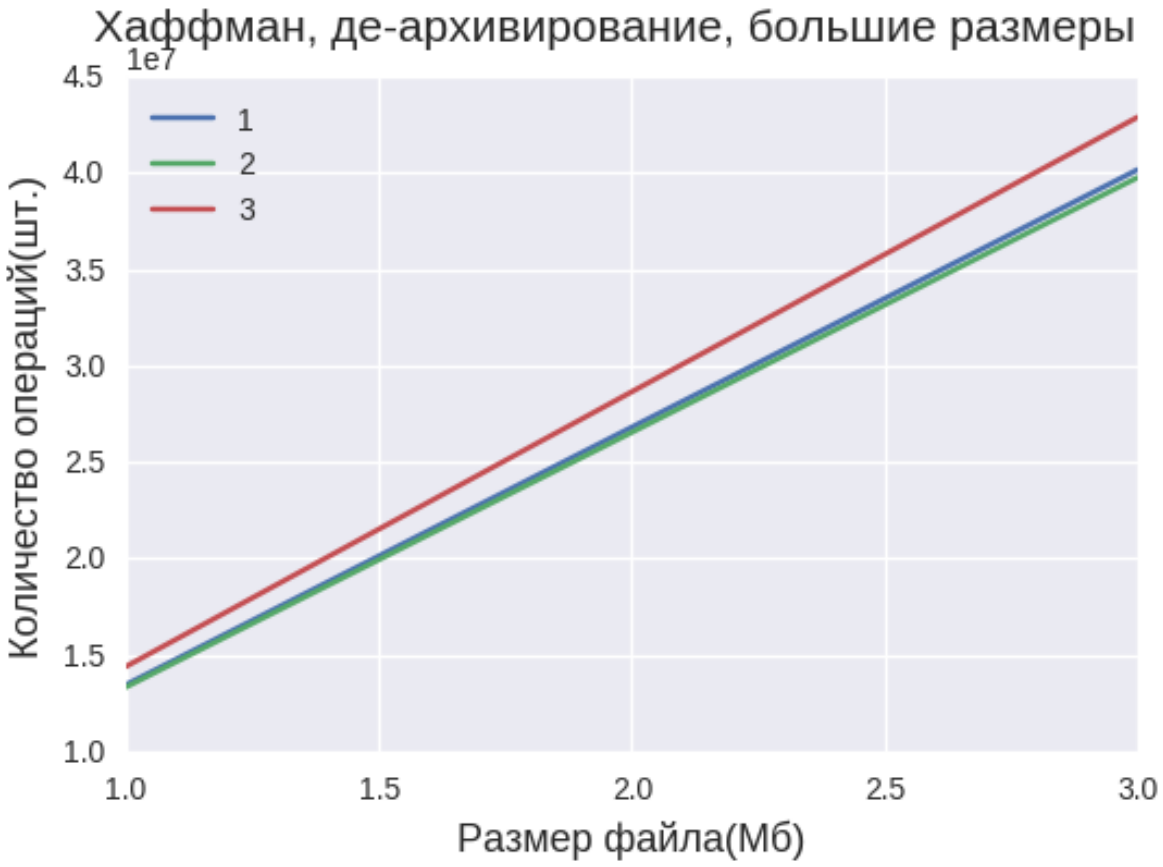
Хаффман, де-архивирование, большие размеры
1e7
4.5
4.0
3.5
3.0
2.5
2.0
1.5
1.0
Количество операций(шт.)
1
2
3
1.0
1.5
2.0
2.5
3.0
Размер файла(Мб)

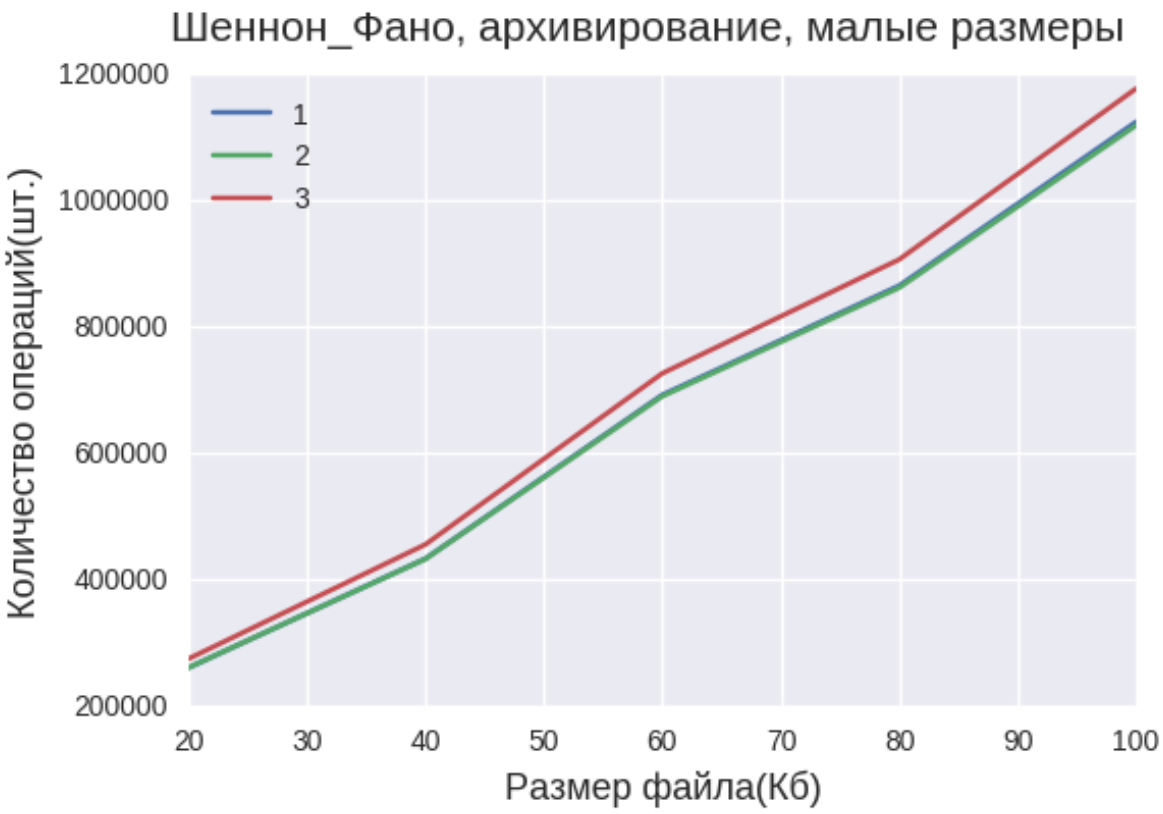
Шеннон_Фано, архивирование, малые размеры
Количество операций(шт.)
Размер файла(Кб)
1
2
3
1200000
1000000
800000
600000
400000
200000
20
30
40
50
60
70
80
90
100

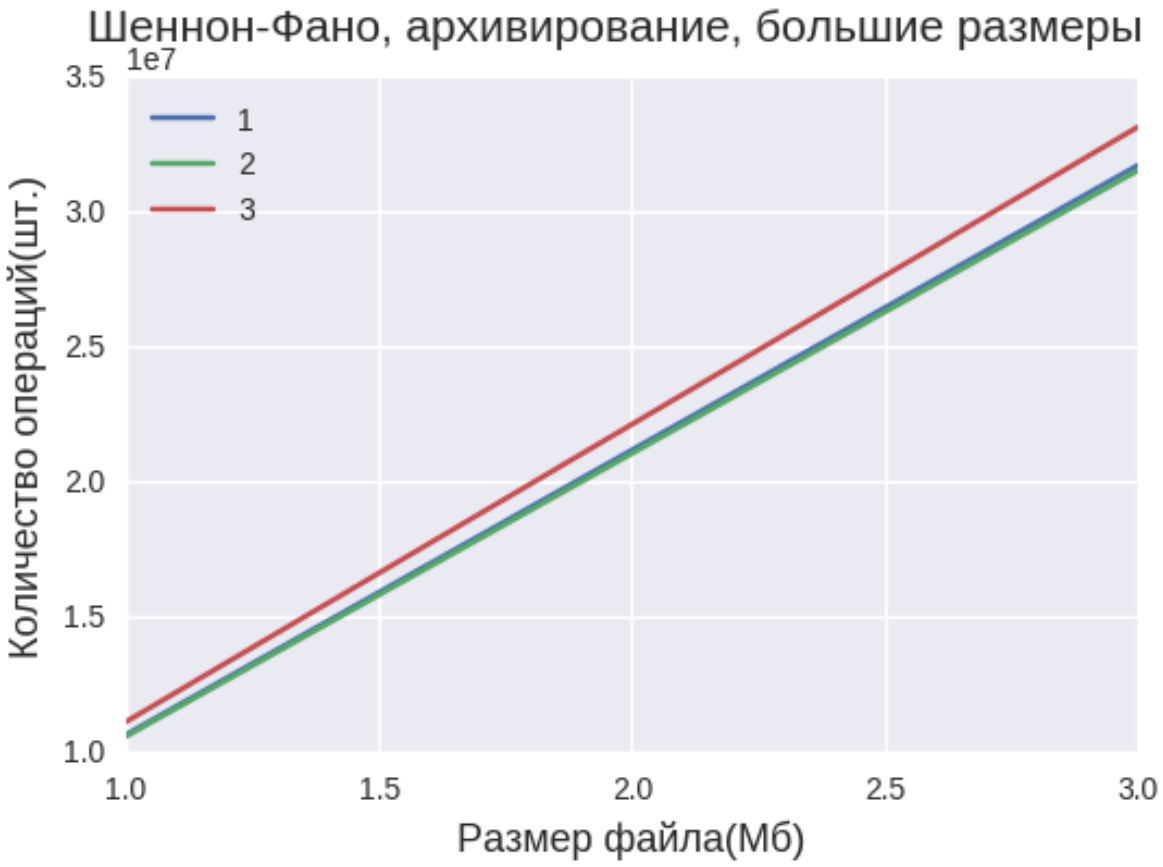
Шеннон-Фано, архивирование, большие размеры
1e7
Количество операций(шт.)
Размер файла(Мб)
1
2
3
3.5
3.0
2.5
2.0
1.5
1.0
1.0
1.5
2.0
2.5
3.0

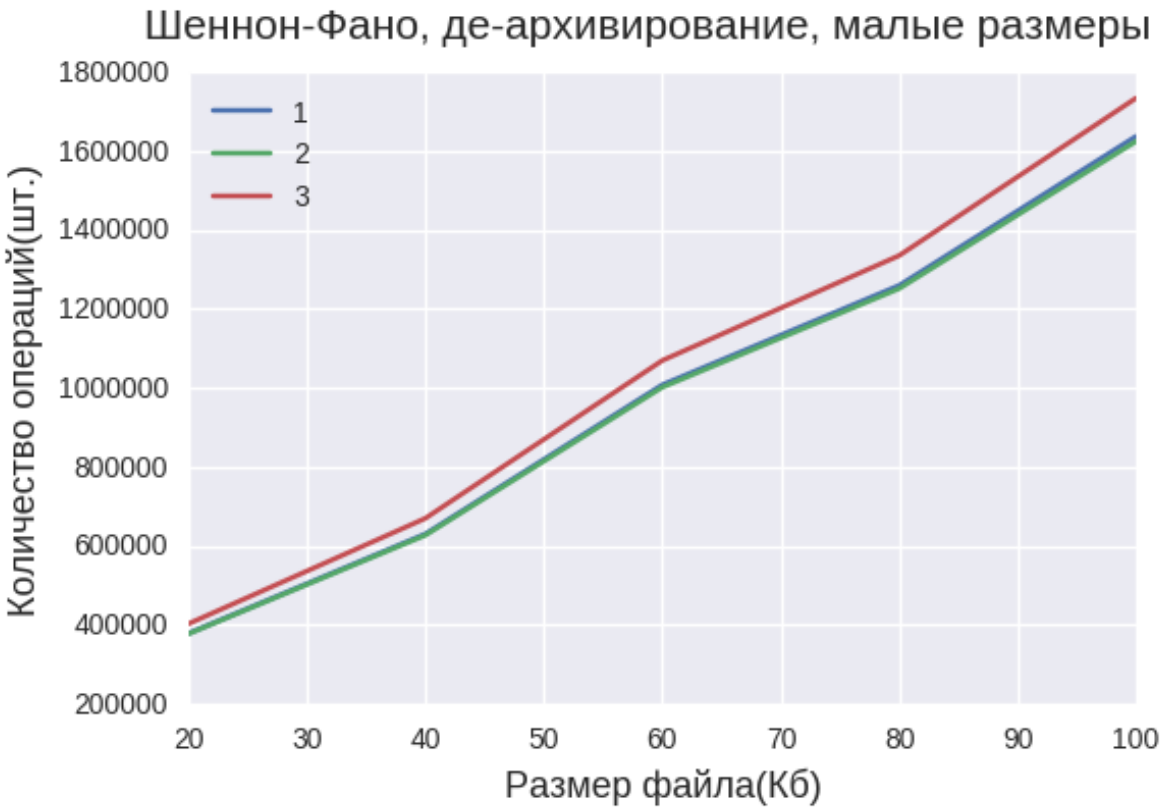
Шеннон-Фано, де-архивирование, малые размеры
Количество операций(шт.)
Размер файла(Кб)
1
2
3
1800000
1600000
1400000
1200000
1000000
800000
600000
400000
200000
20
30
40
50
60
70
80
90
100

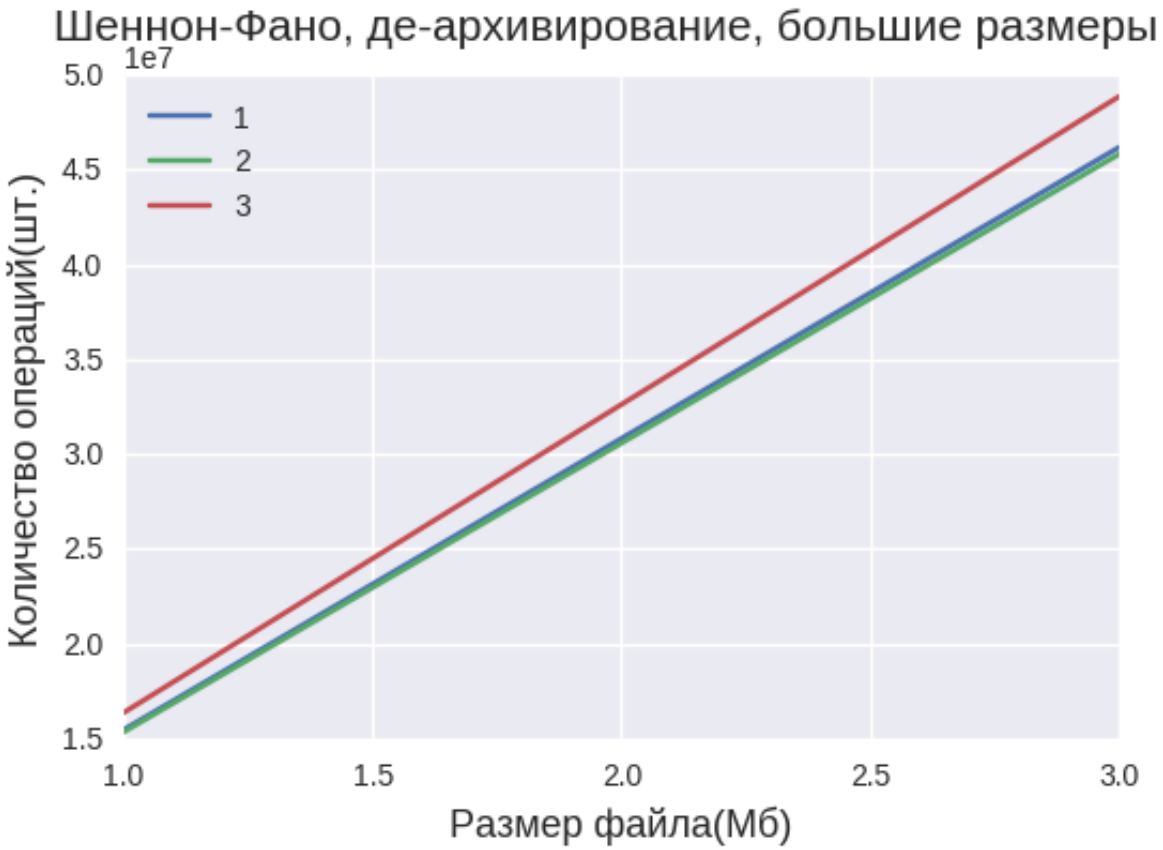
Шеннон-Фано, де-архивирование, большие размеры
1e7
Количество операций(шт.)
Размер файла(Мб)
1
2
3
5.0
4.5
4.0
3.5
3.0
2.5
2.0
1.5
1.0
1.5
2.0
2.5
3.0

4.2.2 Второй набор графиков

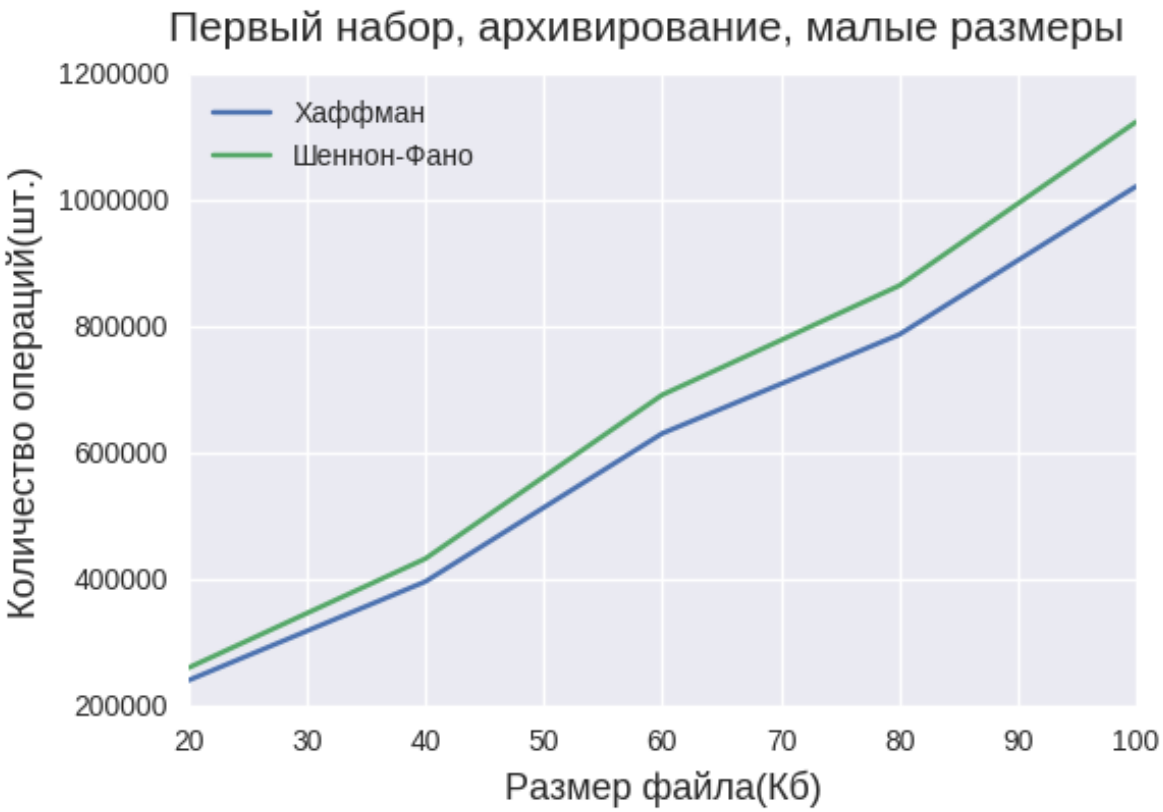

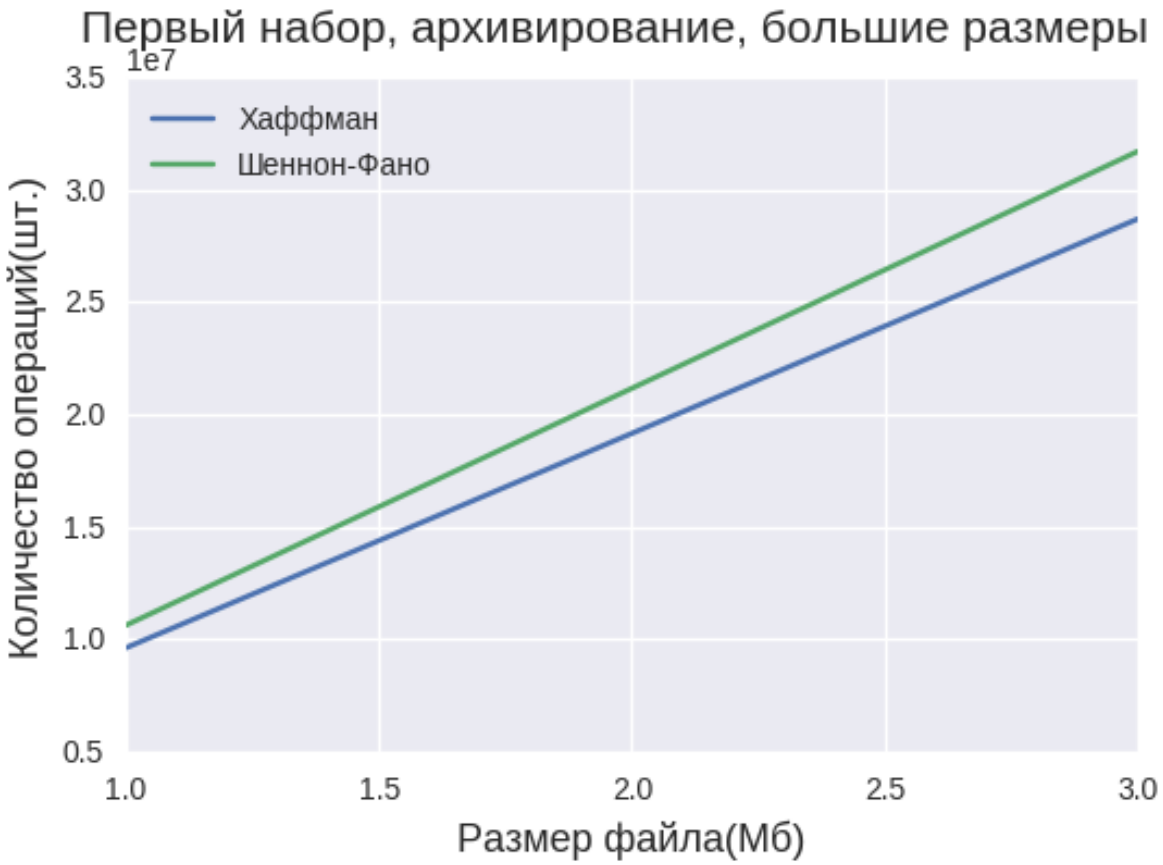

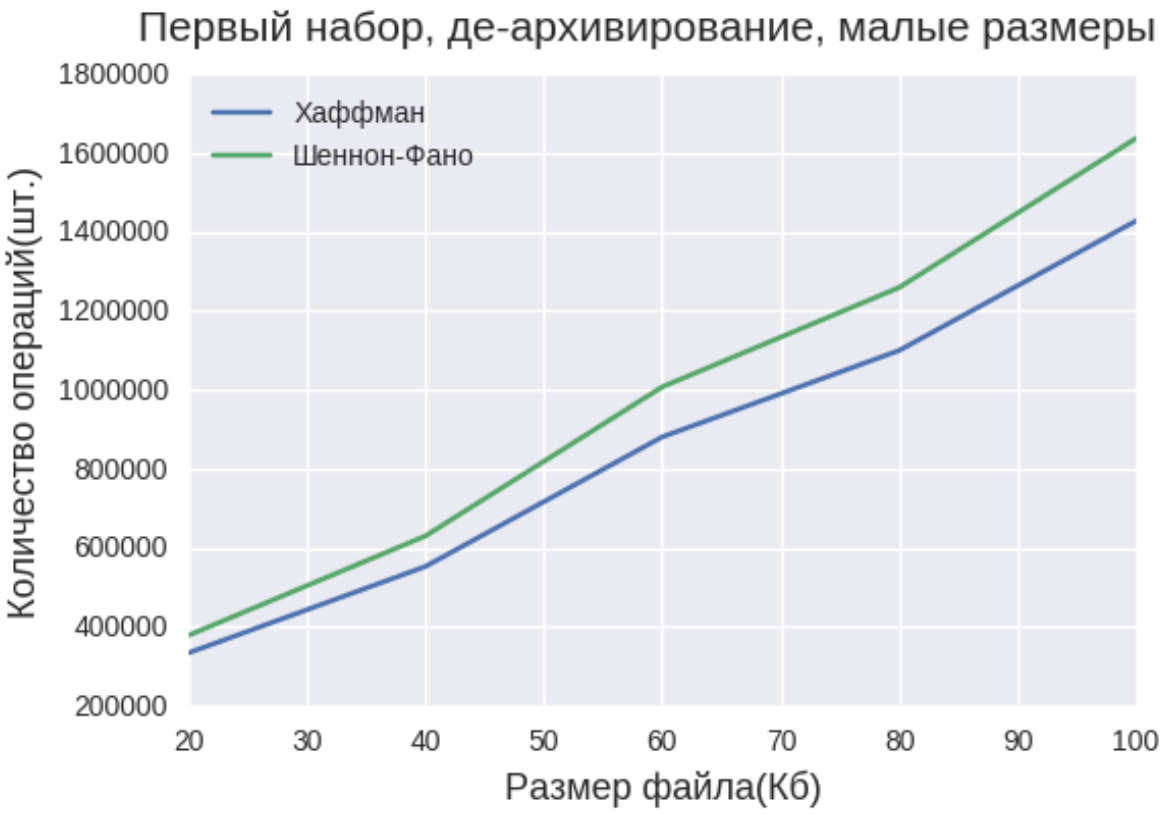
Первый набор, де-архивирование, малые размеры
Хаффман
Шеннон-Фано
Количество операций(шт.)
1800000
1600000
1400000
1200000
1000000
800000
600000
400000
200000
20
30
40
50
60
70
80
90
100
Размер файла(Кб)

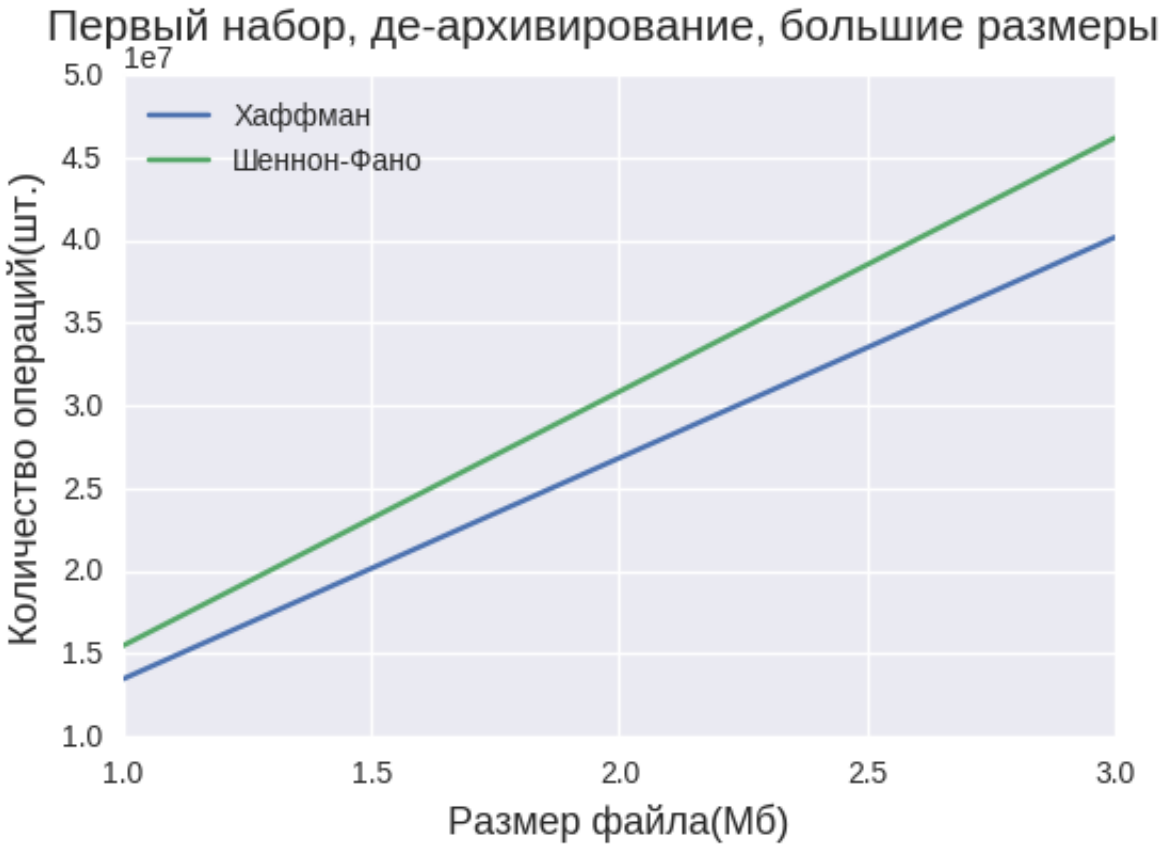
Первый набор, де-архивирование, большие размеры
1e7
Хаффман
Шеннон-Фано
Количество операций(шт.)
5.0
4.5
4.0
3.5
3.0
2.5
2.0
1.5
1.0
1.0
1.5
2.0
2.5
3.0
Размер файла(Мб)

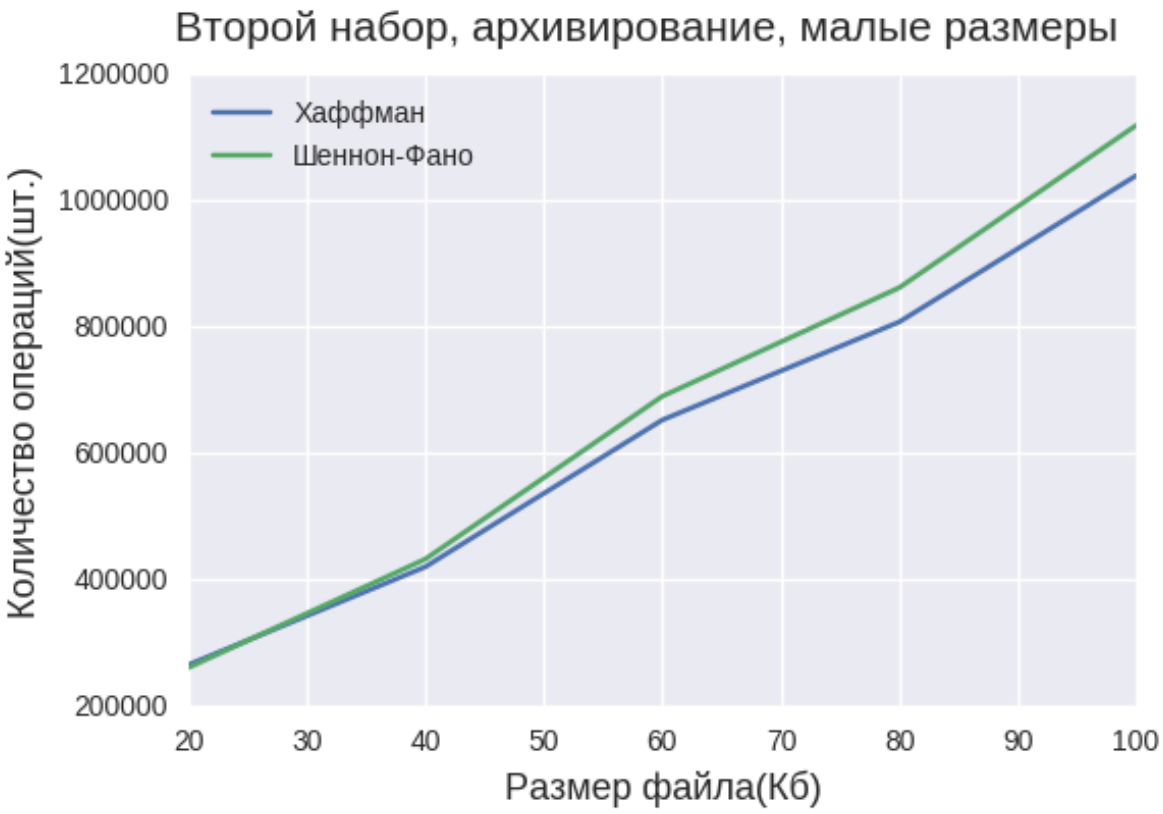
Второй набор, архивирование, малые размеры
Хаффман
Шеннон-Фано
Количество операций(шт.)
1200000
1000000
800000
600000
400000
200000
20
30
40
50
60
70
80
90
100
Размер файла(Кб)

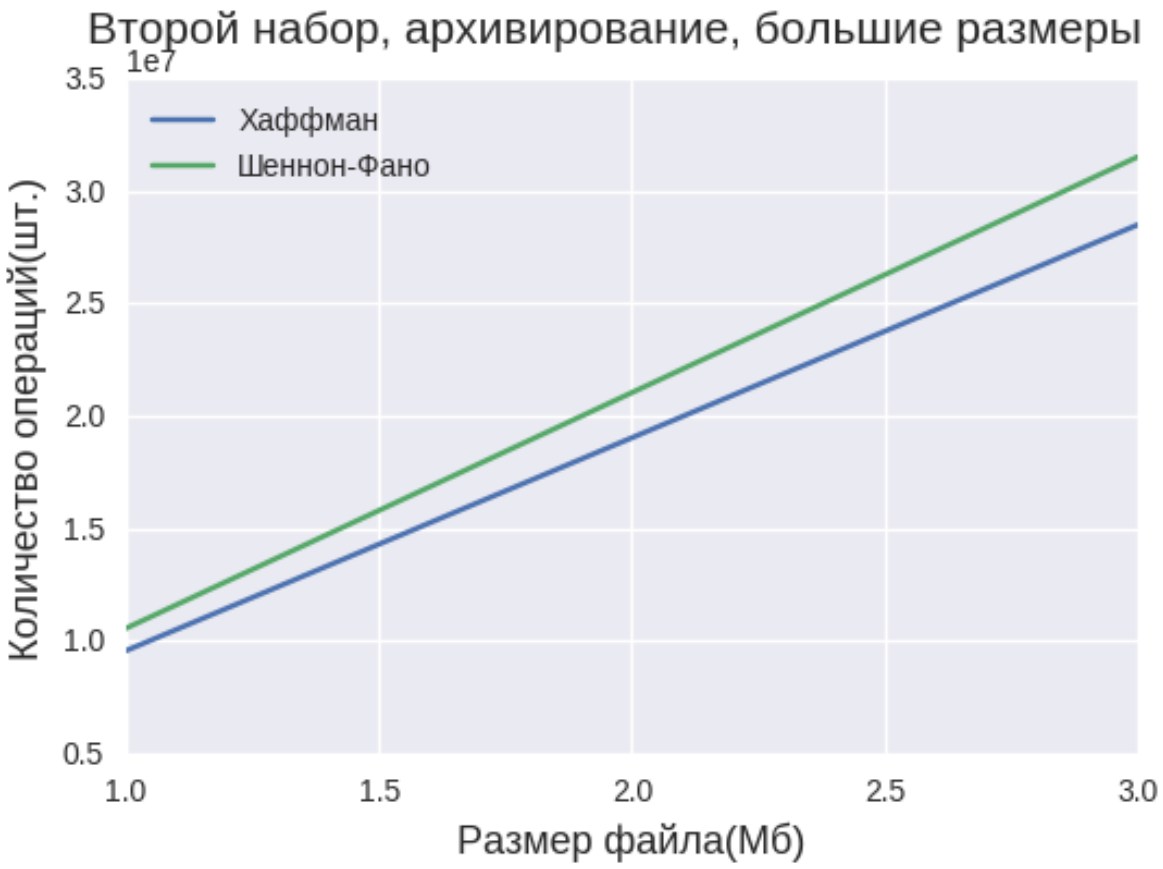
Второй набор, архивирование, большие размеры
1e7
3.5
3.0
2.5
2.0
1.5
1.0
0.5
Хаффман
Шеннон-Фано
Количество операций(шт.)
1.0
1.5
2.0
2.5
3.0
Размер файла(Мб)

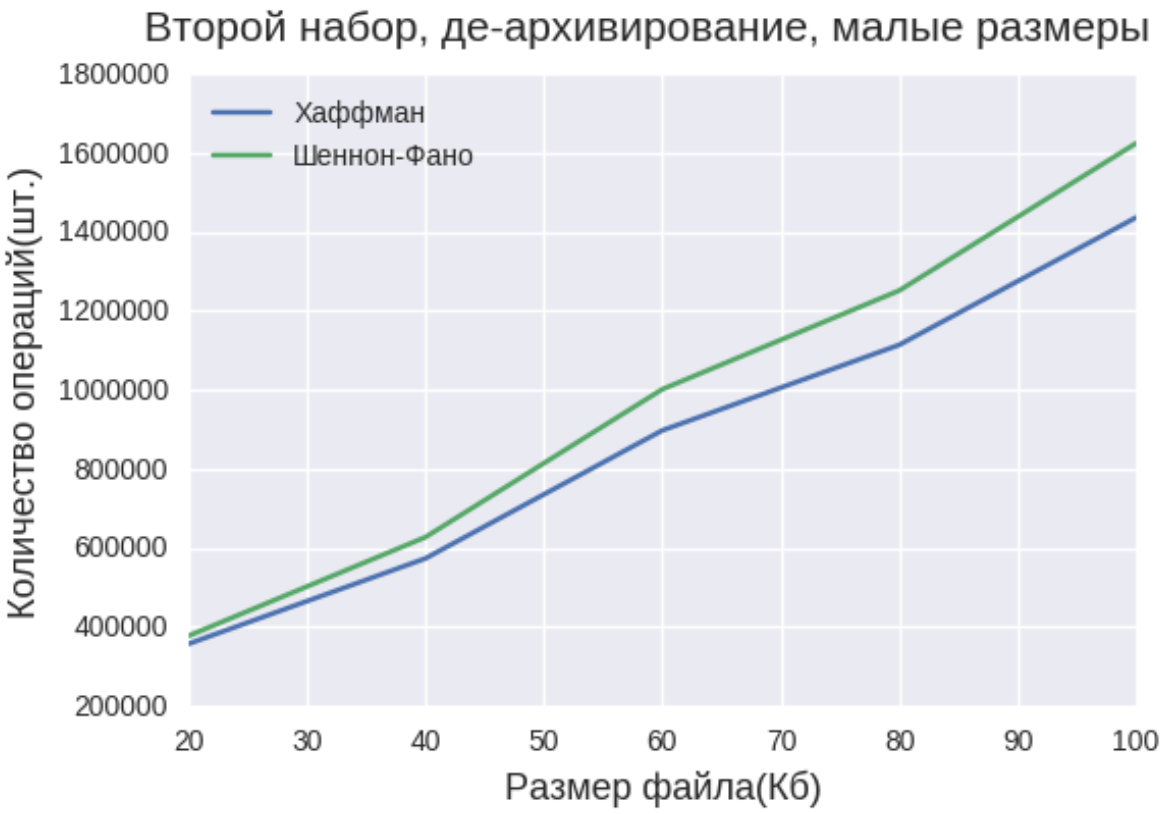
Второй набор, де-архивирование, малые размеры
Хаффман
Шеннон-Фано
Количество операций(шт.)
1800000
1600000
1400000
1200000
1000000
800000
600000
400000
200000
20
30
40
50
60
70
80
90
100
Размер файла(Кб)

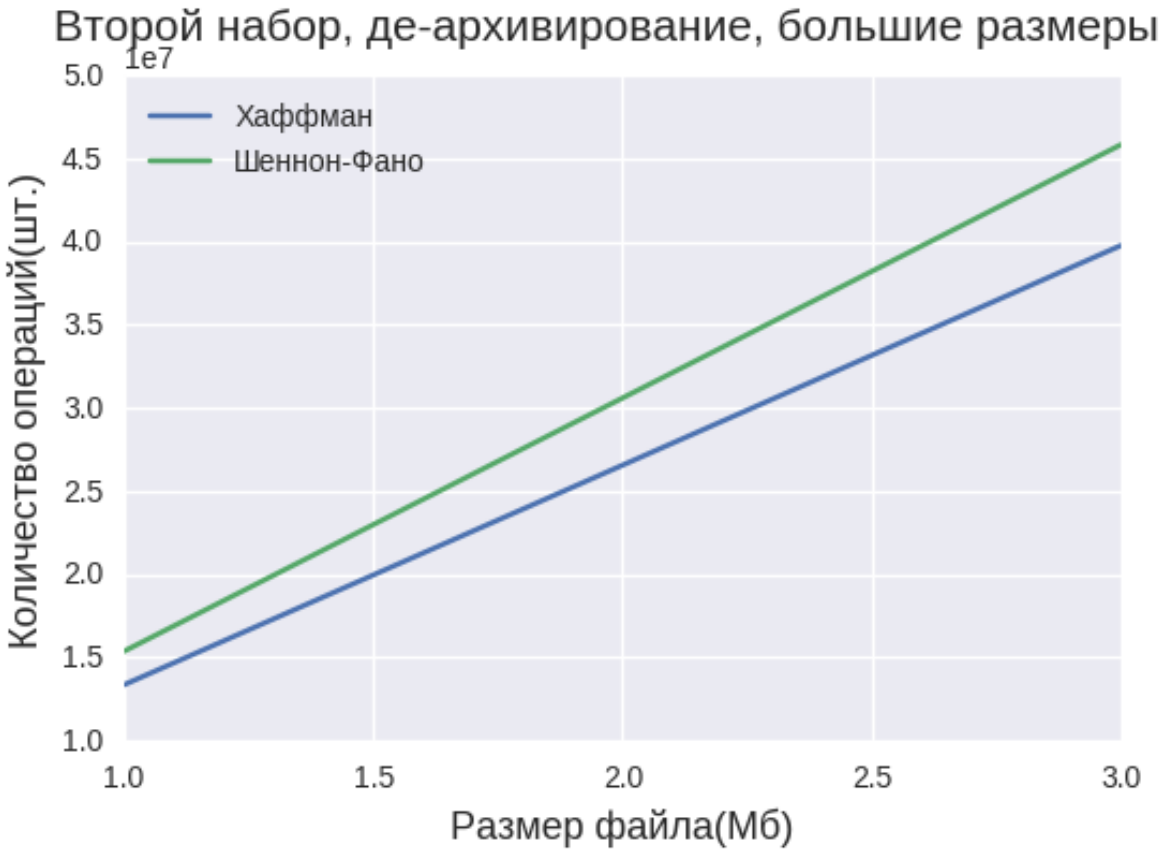
Второй набор, де-архивирование, большие размеры
1e7
Хаффман
Шеннон-Фано
Количество операций(шт.)
5.0
4.5
4.0
3.5
3.0
2.5
2.0
1.5
1.0
1.0
1.5
2.0
2.5
3.0
Размер файла(Мб)

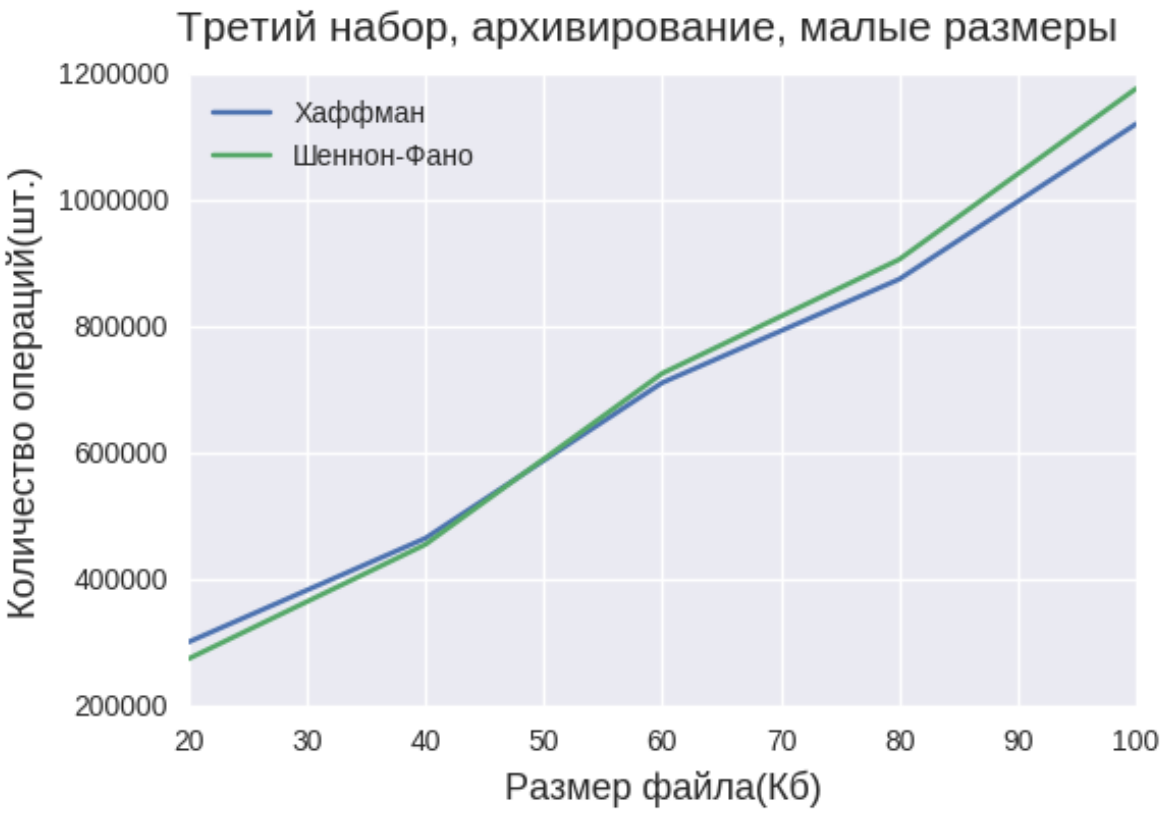
Третий набор, архивирование, малые размеры
Хаффман
Шеннон-Фано
Количество операций(шт.)
1200000
1000000
800000
600000
400000
200000
20
30
40
50
60
70
80
90
100
Размер файла(Кб)

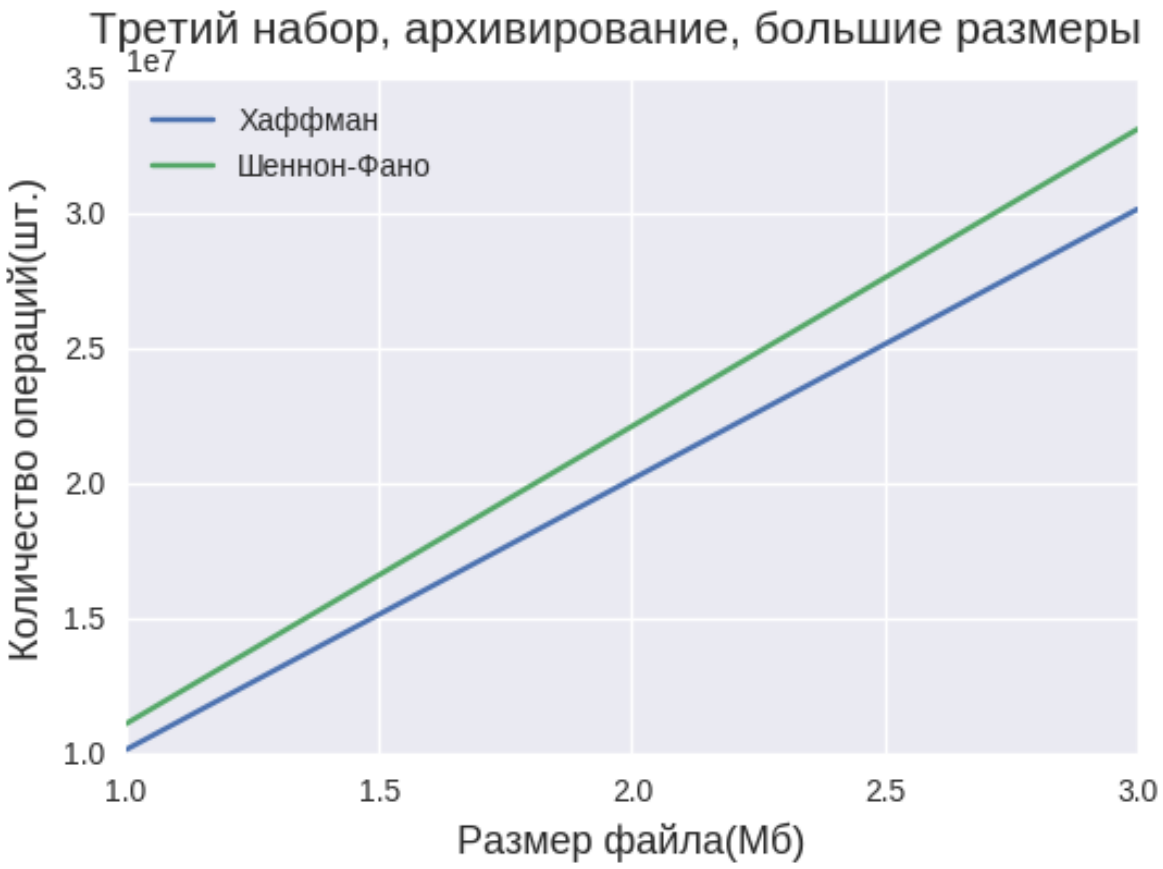
Третий набор, архивирование, большие размеры
1e7
Хаффман
Шеннон-Фано
Количество операций(шт.)
3.5
3.0
2.5
2.0
1.5
1.0
1.0
1.5
2.0
2.5
3.0
Размер файла(Мб)

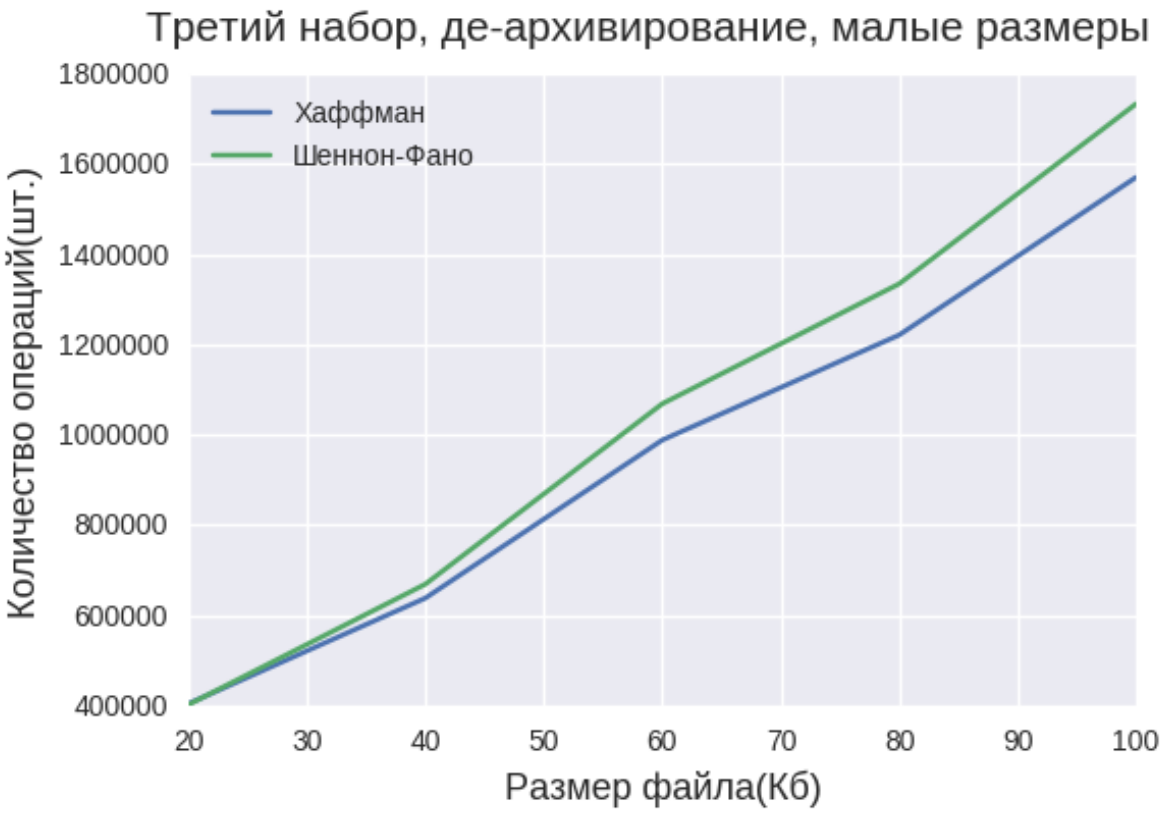
Третий набор, де-архивирование, малые размеры
Хаффман
Шеннон-Фано
Количество операций(шт.)
1800000
1600000
1400000
1200000
1000000
800000
600000
400000
20
30
40
50
60
70
80
90
100
Размер файла(Кб)

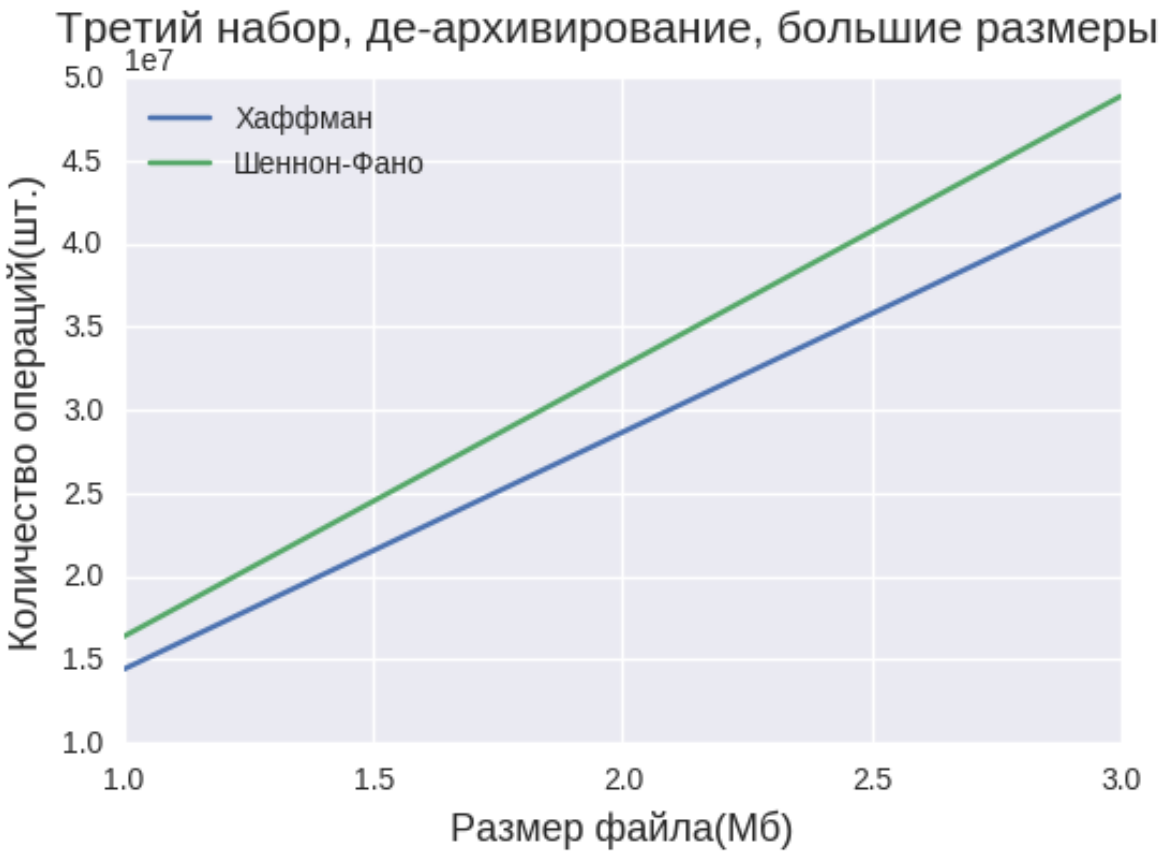
Третий набор, де-архивирование, большие размеры
1e7
Хаффман
Шеннон-Фано
Количество операций(шт.)
5.0
4.5
4.0
3.5
3.0
2.5
2.0
1.5
1.0
1.0
1.5
2.0
2.5
3.0
Размер файла(Мб)

4.2.3 Третий набор графиков

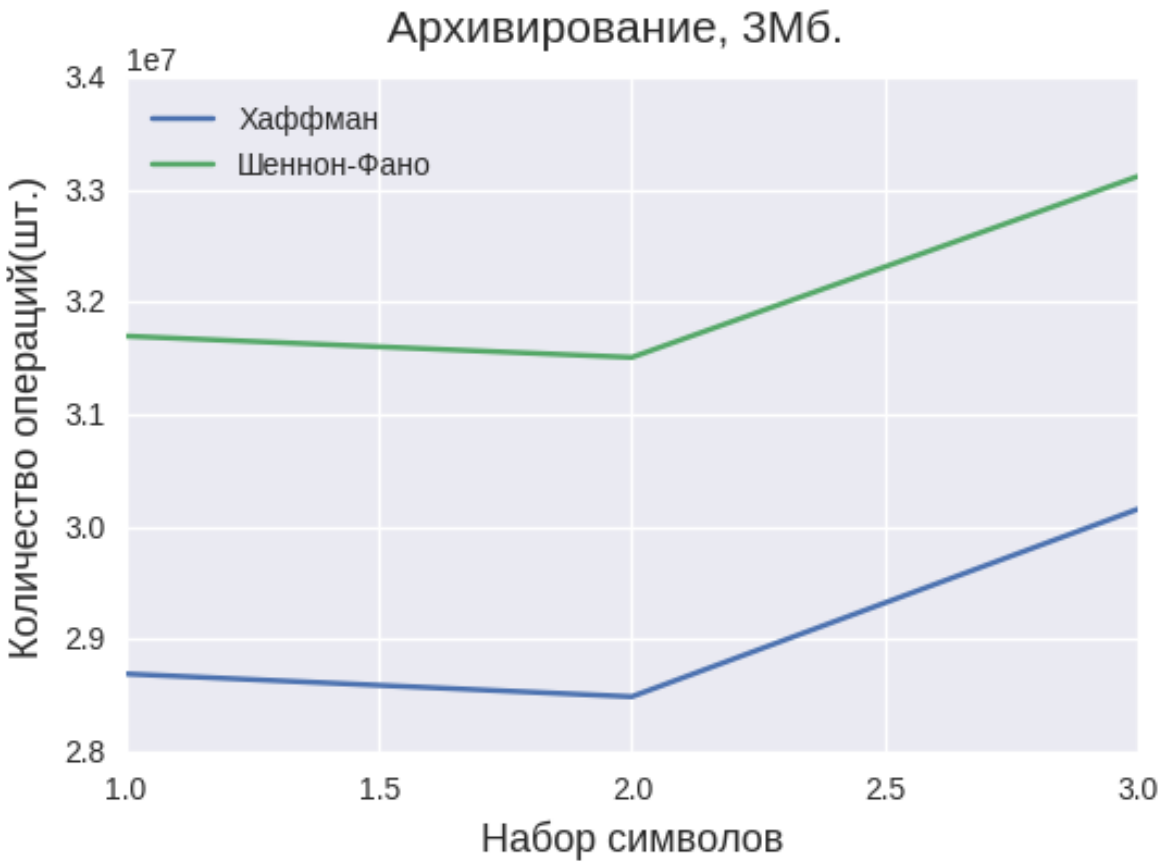

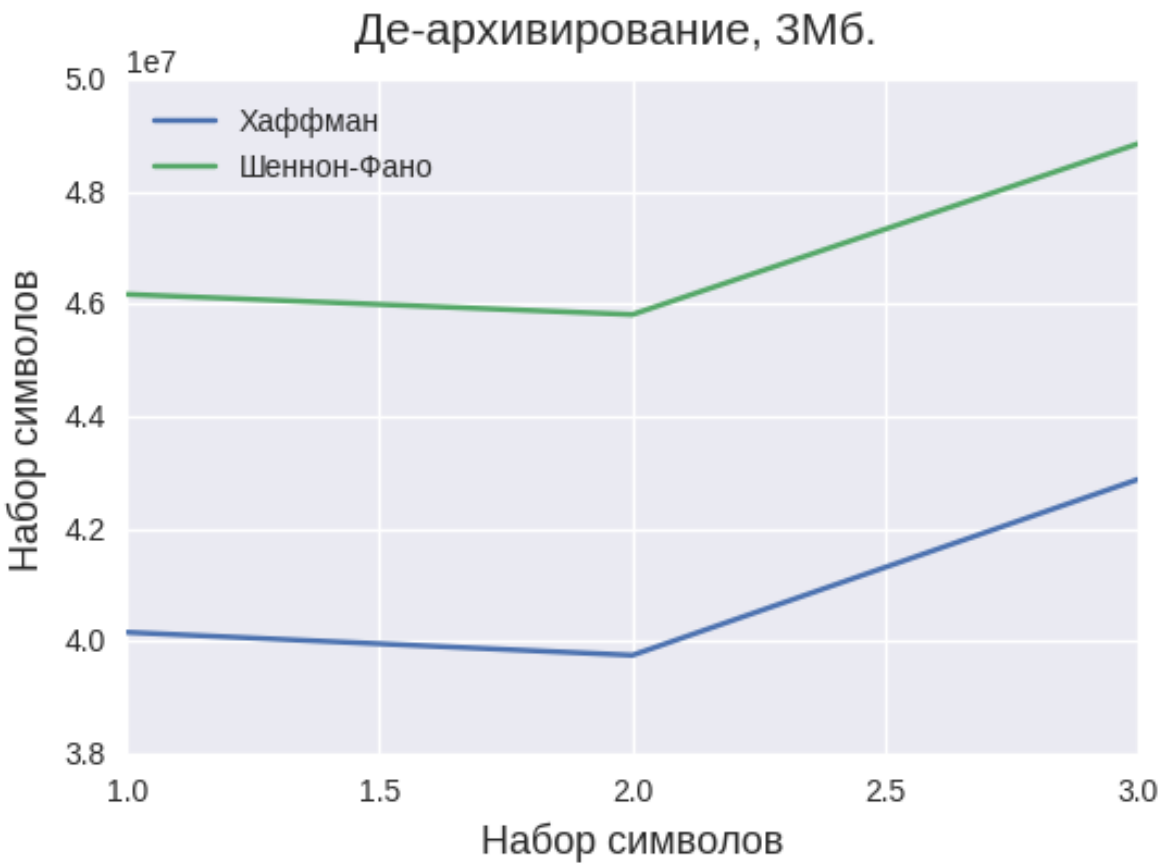

По приведенным графикам видно, что архивирование - разархивирование алгоритмом Хаффмана всегда занимает меньше операций, чем алгоритмом Шеннона-Фано. Еще видно, что третий набор символов (со знаками пунктуаций, скобками, и т.д.) занимает всегда больше операций, чем остальные, причем распределены они сответствующе. То есть наименьшее кол-во операций требует архивация - деархивация файлов с английскими буквами, пробелами и новыми строчками, затем тот же набор, но с русскими буквами, и на третьем месте с символами. Единственное исключение - на третьем наборе графиков, когда на втором наборе кол-во операций меньше, чем на первом.

4.3 Дополнительные графики

Здесь приведены дополнительные графики, а именно, графики, иллюстрирующие степень сжатия файлов в зависимости от используемого алгоритма, набора символов (цвет линии) и размера файлов.

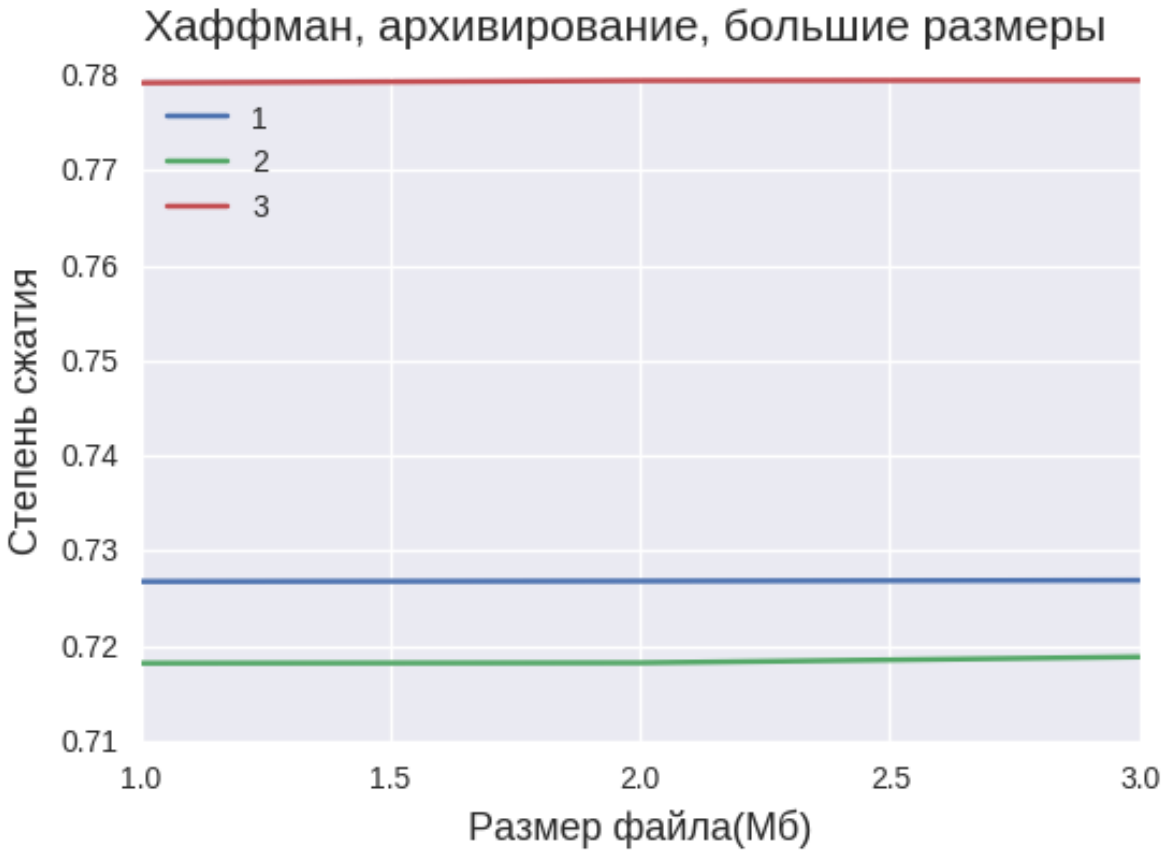

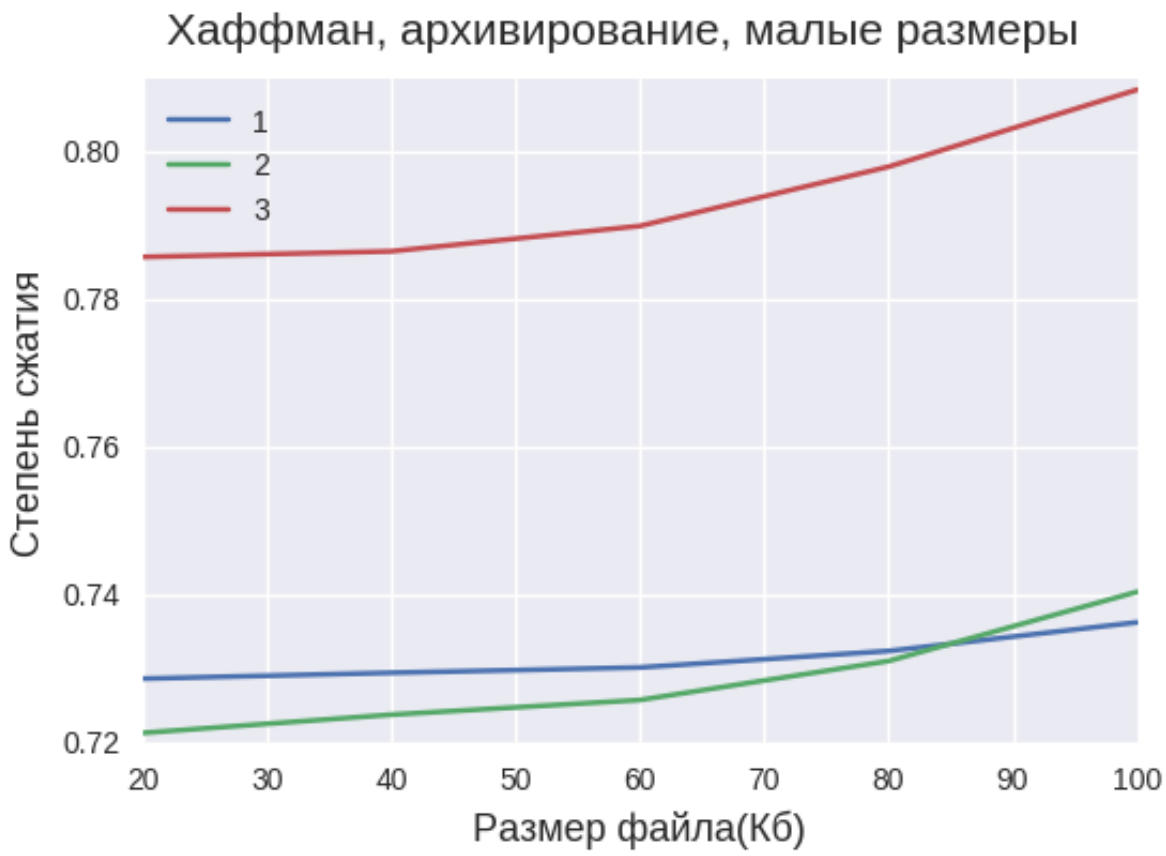

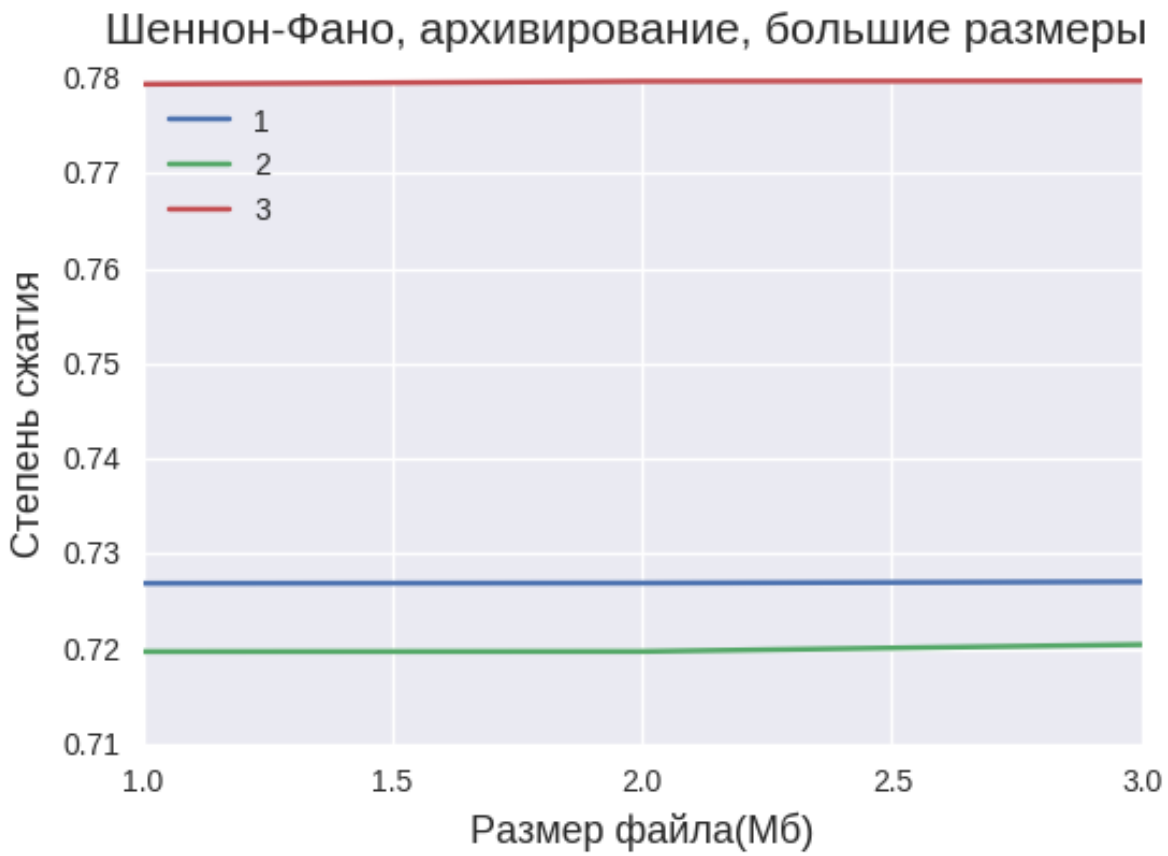

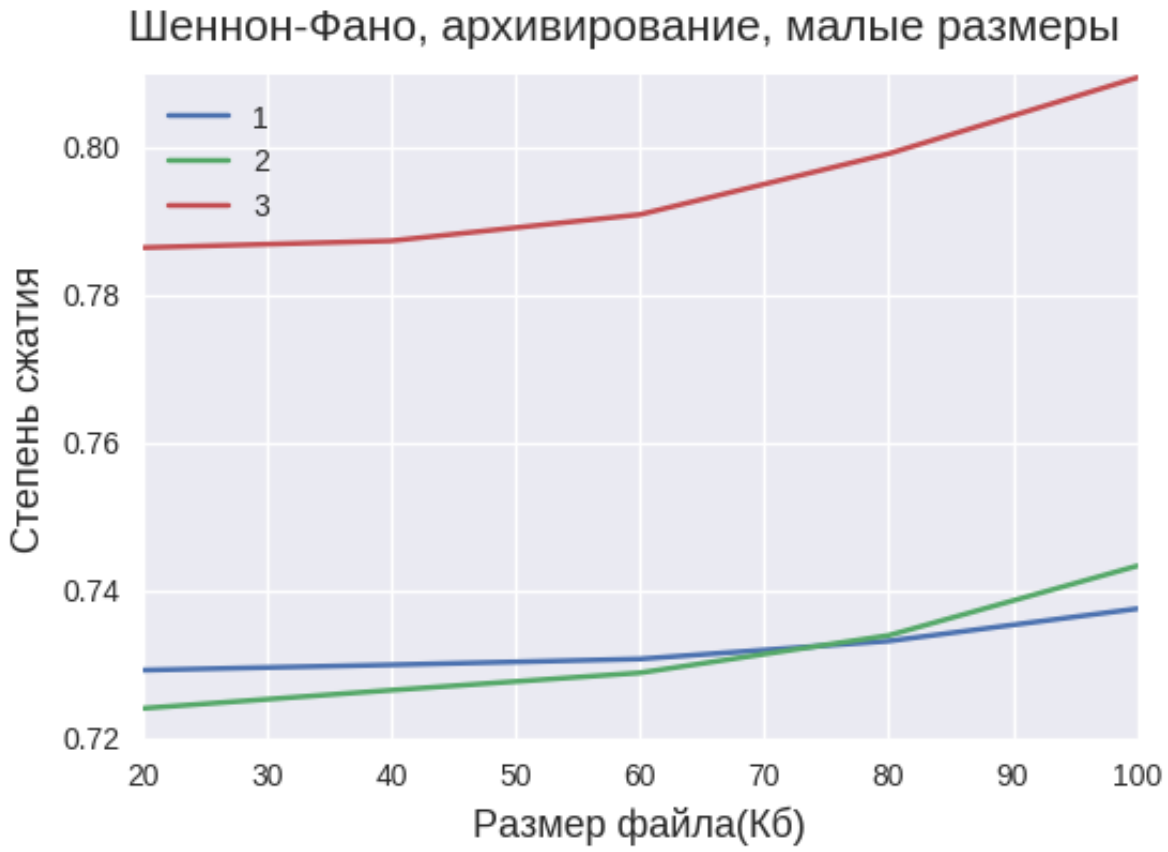

Видно, что чем больше файл - тем больше степнь сжатия. Так же, файлы с третьим набором символов имеют наибольшую степень сжатия. Интересно заметить, что при маленьких размерах файлов, файлы со вторым набором символов и размером до 100 Кб имели меньшую степень сжатия алгоритмом Хаффмана, чем файлы с первым набором символов. Аналогично с алгоритмом Шеннона-Фано, но только для файлов до 80 Кб.

5 Сравнительный анализ методов

Общее сравнение:

В моей реализации алгоритма Шеннона - Фано не использовалось дерево, в отличие от реализации алгоритма Хаффмана. Следовательно, сложность его выше. Если не смотреть конкретно на мою реализацию, то сложность будет примерно одинаковая. Оба алгоритма используют рекрсивные функции для построения дерева, которые работают за $O(n)$.

Сравнение двух алгоритмов:

Шеннон-Фано	**Хаффман**
Дерево строится сверху-вниз	Дерево строится снизу-вверх
Длина кодов в среднем большая	Длина кодов в среднем маленькая
Легко реализуется	Немного сложнее реализуется
Используемые СД: деревья, связные списки	Используемые СД: очереди с приоритетом, связные списки
Нигде не используется	Используется при сжатии JPEG и mp3 файлов

6 Заключение

В ходе работы над проектом была выполнена поставленная в начале задача. С использованием языка C++ была написана программа для архивации и деархивации текстовых файлов. Были сгенерированы тестовые текстовые файлы и проведены необходимые замеры. Составлена таблица, по ней построены и проанализированы графики. Приводу основные выводы, к которым я пришел:

- Степень и скорость сжатия лучше у алгоритма Хаффмана
- Алгоритм Хаффмана гарантирует построение кодов наименьей длины и наименьшим средним числом символов на букву при данном распределении вероятностей, в то время как алгоритм Шеннона - Фано не всегда приводит к однозначному построению кода. Дело в том, что на первой итерации функции ShannonFano, большей по сумме вероятностей може оказаться как первая, так и вторая половина набора. В результате среднее число символов на букву окажется другим. Таким образом, построенный код может оказаться не самым лучшим
- Алгоритм Хаффмана имеет повсеместное применение, используется присжатии изображений в формате JPEG/JPG, а так же для сжатия звука в формат mp3. Существует так же «адаптивный алгоритм Хаффмана», который, считается лучше в некоторых случаях. Он работает в реальном времени, адаптируясь под текущую вероятность символов в кодируемом файле
- Для очень маленьких файлов степень сжатия может быть > 1, поскольку таблица частот, которая запишется в архив, может иметь такой размер, что в сумме с закодированным сообщением будет весить больше исходного текстового файла, не содежащего таблицу